基于 MIMIC-IV Demo 的 ICU 延长住院早期预测

一项可复现的机器学习分析

杨济丞

中国中医科学院医学实验中心，北京

2026 年 11 月

摘要

目的：利用重症监护病房（ICU）入科后 24 小时内的常规临床数据，构建并评估延长 ICU 停留（ICU length of stay, LOS $\geq$ 72 小时）的早期预测模型，展示从数据读取到模型解释的完整可复现流程。

方法：基于公开的 MIMIC-IV Clinical Database Demo v2.2，纳入成人首次 ICU 住院，提取人口学、生命体征、实验室检查和早期干预变量。以 70/30 比例分层划分训练集与测试集，比较 L2 正则化 logistic 回归、随机森林与 XGBoost；在训练集内采用 5 折分层交叉验证和网格搜索优化 AUROC，在独立测试集上报告 AUROC（Bootstrap 95% CI）、PR-AUC、Brier score、校准曲线、决策曲线和 SHAP 解释。

结果：共纳入 128 个首次 ICU 住院，48 例（37.5%）发生延长 ICU 停留，院内死亡 15 例（11.7%）。随机森林的交叉验证 AUROC 最高（0.778），在测试集上 AUROC 为 0.739（95% CI 0.559–0.883），PR-AUC 为 0.698，Brier score 为 0.204；在 Youden 阈值（0.315）下敏感度为 73.3%、特异度为 70.8%。Logistic 回归的测试 AUROC 为 0.750、Brier score 为 0.183。最低 GCS、最高体温、最高乳酸、机械通气和最高心率是贡献最大的预测因素。

结论：仅使用入 ICU 24 小时内常规可获得的数据即可对延长 ICU 停留进行中等程度的早期预测。受 Demo 数据样本量限制，结果应被视为方法学演示，需在完整队列和外部数据中验证。

关键词：重症监护；住院时长；机器学习；预测模型；MIMIC-IV；模型可解释性

Abstract

Objective: To develop and evaluate an early prediction model for prolonged intensive care unit (ICU) stay (length of stay, LOS $\geq$ 72 h) using routinely available data from the first 24 h after ICU admission, and to demonstrate a fully reproducible pipeline from data loading to model interpretation.

Methods: We used the openly available MIMIC-IV Clinical Database Demo v2.2. Adult first ICU stays were included. Demographic, vital-sign, laboratory, and early-intervention variables were extracted. Data were split into training and test sets (70/30, stratified). L2-regularized logistic regression, random forest, and XGBoost were compared; hyperparameters were tuned by five-fold stratified cross-validation with AUROC as the objective. The held-out test set was used to report AUROC (bootstrap 95% CI), PR-AUC, Brier score, calibration, decision-curve analysis, and SHAP explanations.

Results: A total of 128 first ICU stays were included; 48 (37.5%) had prolonged ICU stay and 15 (11.7%) died in hospital. Random forest achieved the highest cross-validated AUROC (0.778) and a test AUROC of 0.739 (95% CI 0.559–0.883), with PR-AUC 0.698 and Brier score 0.204. At the Youden threshold (0.315), sensitivity was 73.3% and specificity 70.8%. Logistic regression achieved a test AUROC of 0.750 and a Brier score of 0.183. The most influential predictors were minimum GCS, maximum temperature, maximum lactate, mechanical ventilation, and maximum heart rate.

Conclusions: Routinely available data from the first 24 h of ICU care provide moderate early discrimination for prolonged ICU stay. Given the limited sample size of the demo database, these findings should be regarded as a methodological demonstration and require validation in the full cohort and external populations.

Keywords: intensive care; length of stay; machine learning; prediction model; MIMIC-IV; explainability

1 引言

重症监护病房（ICU）资源有限，住院时长（length of stay, LOS）直接影响床位周转、医疗费用与家属沟通。能够在入科早期识别可能发生延长 ICU 停留的患者，有助于提前进行床位与人力调配、加强监护和制定出院计划。然而，ICU LOS 受疾病严重度、治疗反应、并发症、出院流程和床位资源等多重因素影响，单一变量难以准确预测 [4]。

电子健康记录（EHR）的普及使得利用常规临床数据构建预测模型成为可能 [1, 3]。MIMIC-IV 是广泛使用的公开重症数据库 [1]，其 Clinical Database Demo 版本无需额外申请即可获取，适合方法学教学与流程复现 [2]。既往 ICU 预测研究多聚焦于死亡、脓毒症或急性肾损伤，针对延长 ICU 停留的早期模型相对较少，且常依赖 SOFA 等评分或较长时间窗的数据。

本研究的目标是：（1）基于 MIMIC-IV Demo 构建一个从数据读取、预处理、统计描述、建模、评估到可视化的完整可复现流程；（2）比较 logistic 回归、随机森林与 XGBoost 在延长 ICU 停留预测中的表现；（3）通过校准曲线、决策曲线和 SHAP 分析评估模型的临床可用性与可解释性。需要强调的是，Demo 数据样本量有限，本研究主要作为方法学演示，而非临床结论。

2 数据与方法

2.1 数据来源

数据来自 MIMIC-IV Clinical Database Demo v2.2（PhysioNet，DOI: 10.13026/dp1f-ex47）[2]。该数据集包含 100 名患者的去标识化住院记录，涵盖 `hosp`（住院）与 `icu`（重症监护）两个模块。数据公开可用，无需 credentialed access。所有分析均遵循 MIMIC-IV 的数据使用规范。

2.2 研究队列与结局

以首次 ICU 住院为分析单位：同一住院号（`hadm_id`）的多次 ICU 转入仅保留第一次，以保证观察独立。纳入标准为年龄 $\geq$ 18 岁。主要结局为延长 ICU 停留，定义为 ICU LOS $\geq$ 72 小时（3

天）；次要描述结局为院内死亡（`hospital_expire_flag`）。年龄按 `anchor_age + (admit_year - anchor_year)` 计算。

2.3 变量提取

提取入 ICU 后 24 小时内的变量：

- **人口学与入科信息**：年龄、性别、是否急诊入院。
- **生命体征**：心率最大值、收缩压最小值、平均动脉压最小值、呼吸频率最大值、体温最大值、GCS 最小值。GCS 总分要求睁眼、语言和运动三个分量在同一时间点齐全。
- **实验室检查**：肌酐、尿素氮、乳酸、白细胞、血钠的最大值。
- **早期干预**：24 小时内是否使用机械通气（含气管插管）和血管活性药（去甲肾上腺素、肾上腺素、多巴胺、多巴酚丁胺、血管加压素、去氧肾上腺素）。
- **衍生变量**：休克指数（心率最大值 / 收缩压最小值）。

对生理学上不可能的极端值进行过滤（如心率 20–300 次/分、收缩压 40–300 mmHg、体温 30–43 °C 等）。缺失值在建模管道内采用中位数插补，且插补参数仅在训练集内拟合，以避免信息泄漏。

2.4 统计分析

连续变量以中位数 [四分位距, IQR] 描述，组间比较采用 Mann–Whitney U 检验；分类变量以例数（百分比）描述，采用卡方检验，期望频数小于 5 时使用 Fisher 精确检验。同时计算标准化均值差（standardized mean difference, SMD）。单因素关联采用 logistic 回归，连续变量按 1 个标准差（SD）标准化，报告比值比（OR）及 95% CI。变量间相关性采用 Spearman 相关系数评估。

2.5 预测模型

数据按 70/30 比例分层划分为训练集和测试集。比较以下三种模型：

1. **L2 正则化 logistic 回归**：正则化强度 $C \in \{0.01, 0.1, 1, 10\}$；
2. **随机森林**：树数 500，最大深度 $\in \{2, 3, 4, \text{None}\}$，叶节点最小样本数 $\in \{2, 4, 8\}$，每次分裂特征数 $\in \{\sqrt{p}, 0.5p\}$；
3. **XGBoost**：学习率 0.05，树数 400，最大深度 $\in \{2, 3\}$，L2 正则化系数 $\lambda \in \{1, 5, 10\}$。

所有模型均采用 5 折分层交叉验证，以 AUROC 为优化目标进行网格搜索。模型选择依据交叉验证 AUROC，而非测试集表现。未使用类别权重，以保持预测概率的可校准性。

2.6 模型评估与可视化

在独立测试集上报告：AUROC 及 2000 次 Bootstrap 重采样得到的 95% CI、PR-AUC、Brier score、校准曲线、决策曲线分析（decision curve analysis, DCA）、Youden 阈值下的混淆矩阵与敏感度/特异度/PPV/NPV/F1。采用 SHAP（SHapley Additive exPlanations）解释特征贡献 [5]。

分析在服务器端 Python 3.13 环境完成，主要依赖 pandas 3.1、scikit-learn 1.9、XGBoost 3.4 和 SHAP 0.54；完整代码见 Jupyter Notebook。

3 结果

3.1 队列特征

研究流程见图 1。数据库包含 275 次住院、140 个 ICU stay，对应 128 次不同的住院；保留首次 ICU 住院后共 128 例成人患者。其中 48 例（37.5%）发生延长 ICU 停留，80 例（62.5%）未发生；院内死亡 15 例（11.7%）。中位年龄 63.0 岁（IQR 52.0–72.8），男性 69 例（53.9%），急诊入院 91 例（71.1%）。

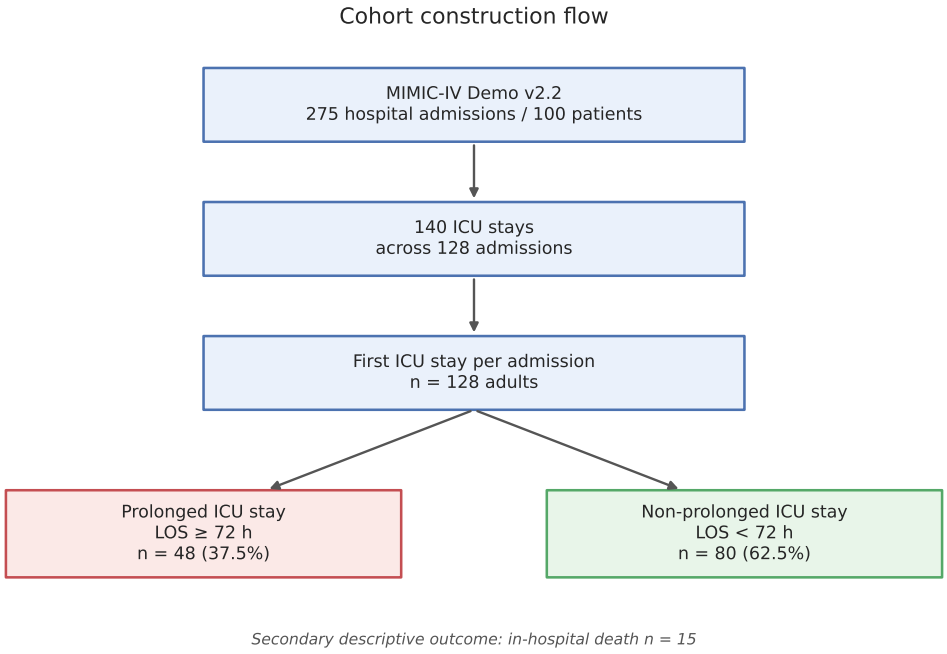


图 1: 队列构建流程。Cohort construction flow.

基线特征见表 1。与未延长组相比，延长组的心率更高、收缩压和平均动脉压更低、体温更高、GCS 更低、BUN 和乳酸更高、白细胞和血钠更高、休克指数更大，差异均具有统计学意义（$P < 0.05$）。延长组的血管活性药使用率（56.2% vs 20.0%）和机械通气率（56.2% vs 21.2%）显著更高，院内死亡率也更高（20.8% vs 6.2%）。年龄、性别、急诊入院比例和呼吸频率在两组间差异无统计学意义。

表 1: 基线特征。Baseline characteristics of the study cohort.

变量 / Variable	总体 (n=128)	未延长 (n=80)	延长 (n=48)	p	SMD
Age (years)	63.0 [52.0, 72.8]	63.5 [52.8, 71.2]	63.0 [51.0, 78.0]	0.811	0.04
Heart rate, max (bpm)	105.5 [94.0, 118.2]	103.0 [91.0, 113.2]	113.5 [97.5, 127.5]	0.002	0.60
Systolic BP, min (mmHg)	90.0 [80.0, 101.0]	92.0 [84.5, 102.0]	86.5 [74.5, 92.2]	0.002	-0.63
Mean arterial pressure, min (mmHg)	60.0 [52.5, 66.0]	62.0 [55.0, 66.0]	57.5 [47.0, 62.2]	0.002	-0.67
Respiratory rate, max (/min)	27.0 [24.0, 30.2]	26.0 [22.0, 31.0]	28.5 [25.0, 30.0]	0.166	0.14
Temperature, max (°C)	37.2 [36.9, 37.6]	37.1 [36.9, 37.4]	37.3 [37.1, 38.1]	0.010	0.54
GCS, min	14.0 [5.0, 15.0]	14.0 [10.8, 15.0]	8.0 [3.0, 14.0]	<0.001	-0.69
Creatinine, max (mg/dL)	0.9 [0.7, 1.6]	0.9 [0.6, 1.3]	1.1 [0.7, 2.2]	0.095	0.16
BUN, max (mg/dL)	19.0 [14.0, 34.5]	18.0 [13.0, 28.0]	22.0 [15.0, 45.0]	0.042	0.37
Lactate, max (mmol/L)	2.2 [1.4, 3.1]	1.8 [1.3, 2.7]	2.8 [1.6, 4.4]	0.009	0.53
WBC, max ($\times 10^9$/L)	11.9 [9.3, 16.5]	10.8 [9.1, 15.3]	13.7 [9.8, 18.4]	0.047	0.35
Sodium, max (mmol/L)	139.0 [136.0, 141.0]	139.0 [135.8, 141.0]	140.0 [138.0, 142.0]	0.022	0.26
Shock index (HR/SBP)	1.2 [1.0, 1.4]	1.1 [1.0, 1.3]	1.3 [1.1, 1.7]	<0.001	0.81
Male sex	69 (53.9%)	45 (56.2%)	24 (50.0%)	0.615	-0.13
Emergency admission	91 (71.1%)	58 (72.5%)	33 (68.8%)	0.801	-0.08
Vasopressor use ≤24 h	43 (33.6%)	16 (20.0%)	27 (56.2%)	<0.001	0.80
Mechanical ventilation ≤24 h	44 (34.4%)	17 (21.2%)	27 (56.2%)	<0.001	0.77
In-hospital death	15 (11.7%)	5 (6.2%)	10 (20.8%)	0.028	0.44

注：连续变量为中位数 [IQR]，分类变量为例数（百分比）。SMD，标准化均值差。

关键变量的分布见图 2。延长组的 GCS 分布明显更低，乳酸和 BUN 分布右移，心率更高；年龄分布在两组间高度重叠。

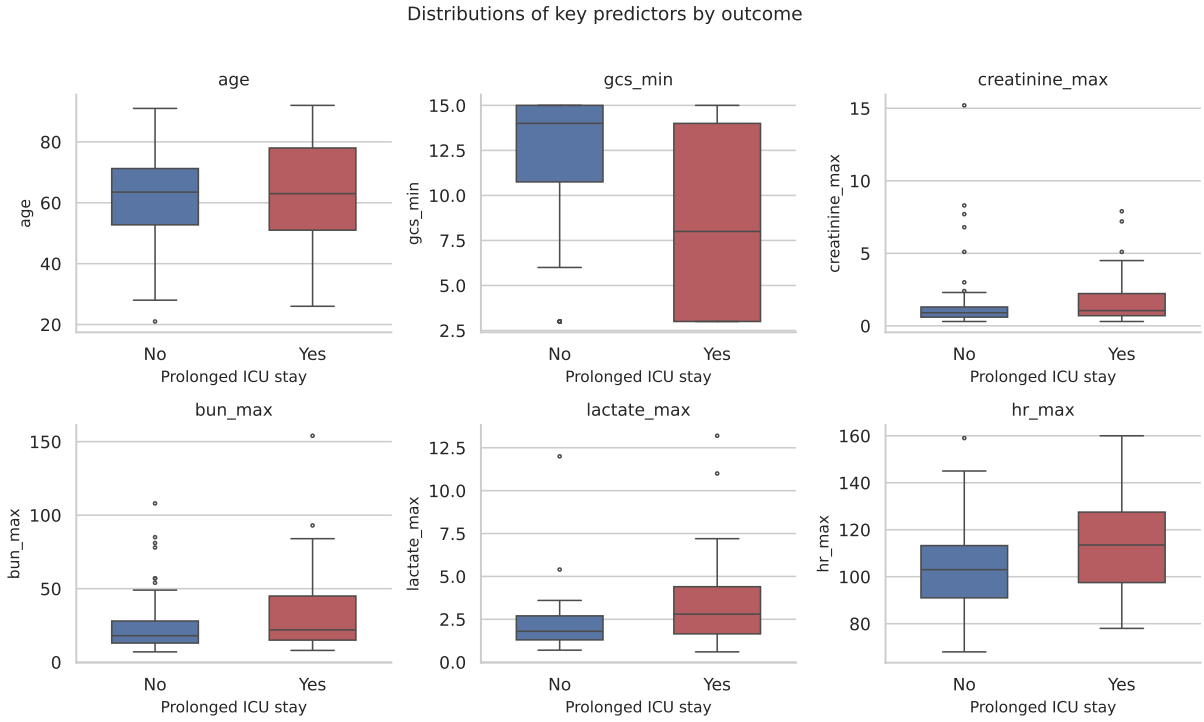


图 2: 关键预测变量按结局分组的分布。Distributions of key predictors by outcome.

3.2 单因素分析

单因素 logistic 回归结果见图 3。与延长 ICU 停留关联最强的变量包括血管活性药使用（OR 5.14, 95% CI 2.33–11.34）、机械通气（OR 4.76, 95% CI 2.18–10.42）、休克指数（每增加 1 SD，OR 2.66）、乳酸（每增加 1 SD，OR 2.25）和心率（每增加 1 SD，OR 1.88）。GCS、收缩压和平均动脉压升高则与风险降低相关。

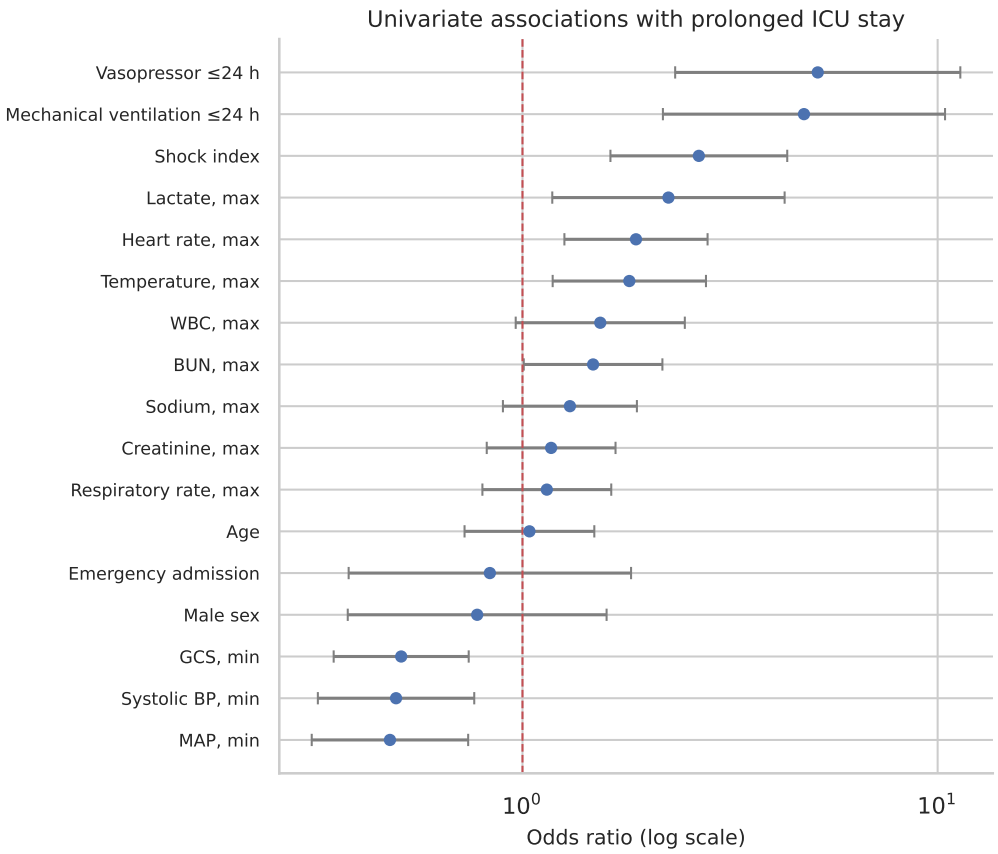


图 3: 延长 ICU 停留的单因素关联。Univariate associations with prolonged ICU stay. 连续变量按 1 SD 标准化；横轴为对数尺度。

3.3 模型性能

训练集包含 89 例（33 个事件），测试集包含 39 例（15 个事件）。三种模型的交叉验证与测试集表现见表 2。随机森林的交叉验证 AUROC 最高（0.778, SD 0.129），被预先选定为主模型；其在测试集上的 AUROC 为 0.739（95% CI 0.559–0.883），PR-AUC 为 0.698，Brier score 为 0.204。Logistic 回归的交叉验证 AUROC 为 0.760，测试 AUROC 为 0.750（95% CI 0.566–0.906），Brier score 为 0.183，校准优于随机森林。XGBoost 的表现略低（测试 AUROC 0.703）。

表 2: 模型性能。Model performance on cross-validation and the held-out test set.

模型 / Model	CV AUC	测试 AUROC (95% CI)	PR-AUC	Brier	敏感度	特异度	F1
Logistic	0.760	0.75 (0.566–0.906)	0.702	0.183	0.667	0.833	0.69
Random Forest	0.778	0.739 (0.559–0.883)	0.698	0.204	0.733	0.708	0.667
XGBoost	0.725	0.703 (0.515–0.864)	0.689	0.212	0.533	0.833	0.593

注：CV AUC 为 5 折交叉验证的平均值；测试 AUROC 的 95% CI 由 2000 次 Bootstrap 重采样得到；敏感度、特异度和 F1 基于 Youden 阈值。

ROC 与 PR 曲线见图 4。三条 ROC 曲线在测试集上较为接近，随机森林在低假阳性率区域略优；PR 曲线显示，在召回率 0.4–0.7 的区间内，三种模型的精确率约为 0.6–0.75。

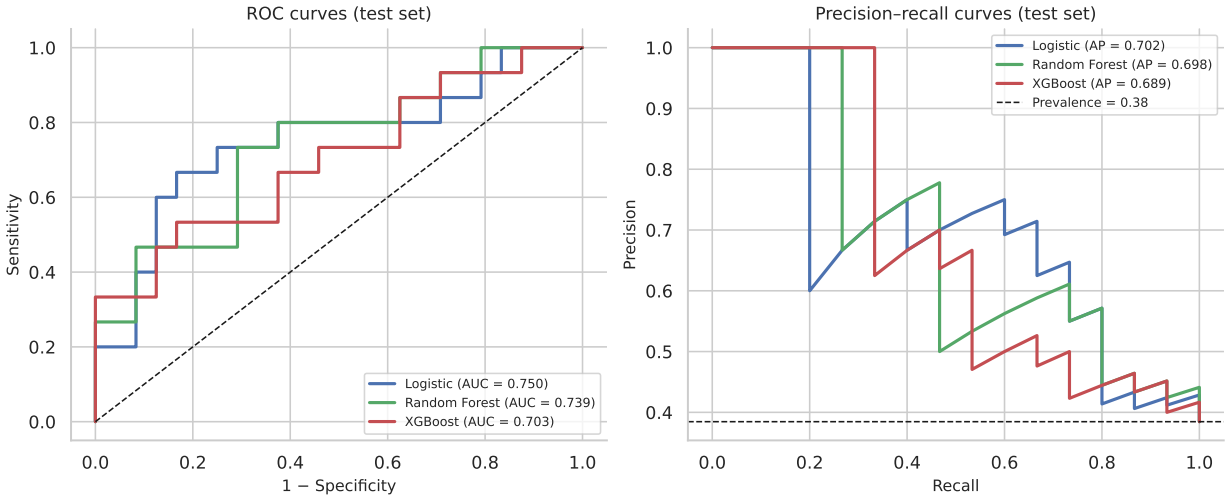


图 4: 测试集 ROC 与 PR 曲线。ROC and precision–recall curves on the test set.

校准曲线见图 5。Logistic 回归的校准曲线整体最接近对角线，Brier score 最低；随机森林在高预测概率区间倾向于低估风险，XGBoost 在低概率区间高估风险。由于测试集仅 39 例，校准曲线呈现明显的阶梯状，解释时应谨慎。

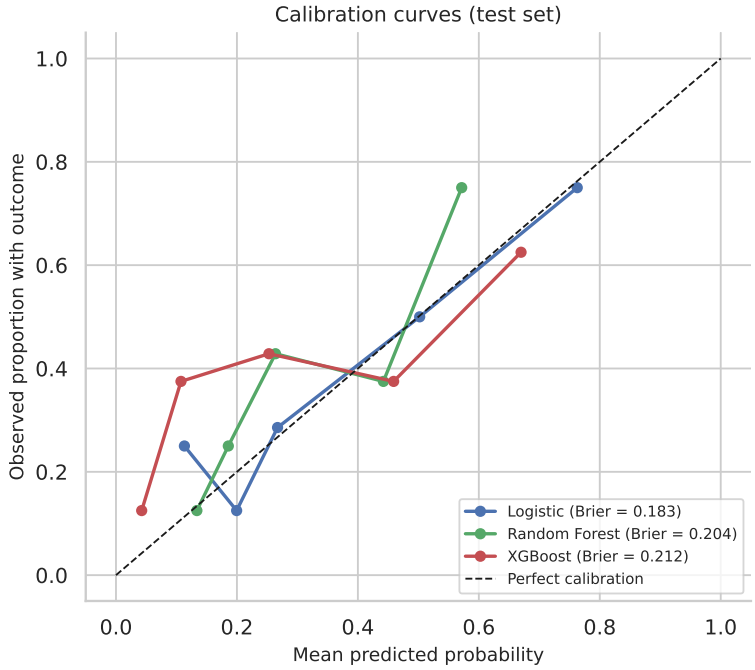


图 5: 测试集校准曲线。Calibration curves on the test set.

决策曲线见图 6。在阈值概率约 0.10–0.50 的范围内，三种模型的净获益均高于“全部干预”和“不干预”策略；当阈值超过约 0.55 后，曲线波动增大，模型间差异不再稳定。

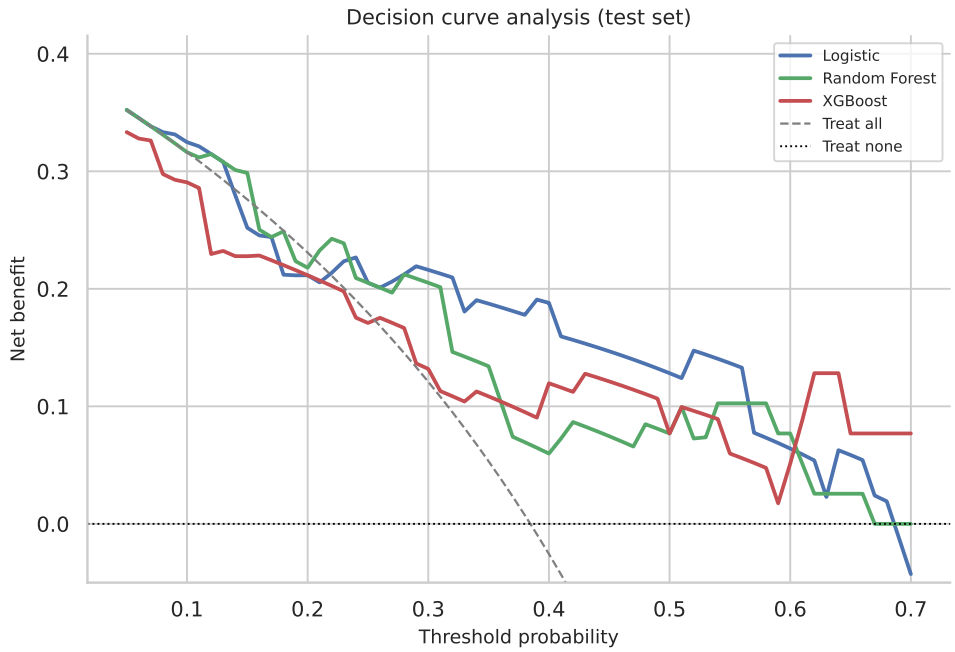


图 6: 测试集决策曲线分析。Decision curve analysis on the test set.

以随机森林在 Youden 阈值 0.315 下的混淆矩阵见图 7：真阳性 11 例、假阳性 7 例、假阴性 4 例、真阴性 17 例；敏感度 73.3%，特异度 70.8%，PPV 61.1%，NPV 81.0%，F1 66.7%。

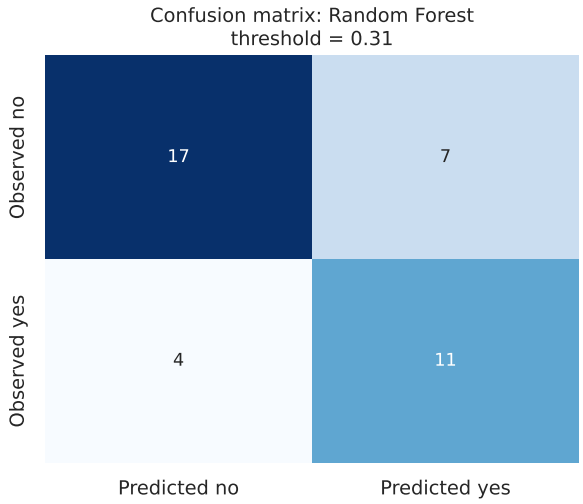


图 7: 随机森林在 Youden 阈值下的混淆矩阵。Confusion matrix of the random forest at the Youden threshold.

3.4 特征重要性与 SHAP 解释

随机森林的基尼重要性排序见图 8。最低 GCS 是最重要的预测因素，其后依次为最高体温、最高乳酸、机械通气、最高心率和呼吸频率；肌酐、BUN、血钠、休克指数和血管活性药也提供了较小但非零的贡献。

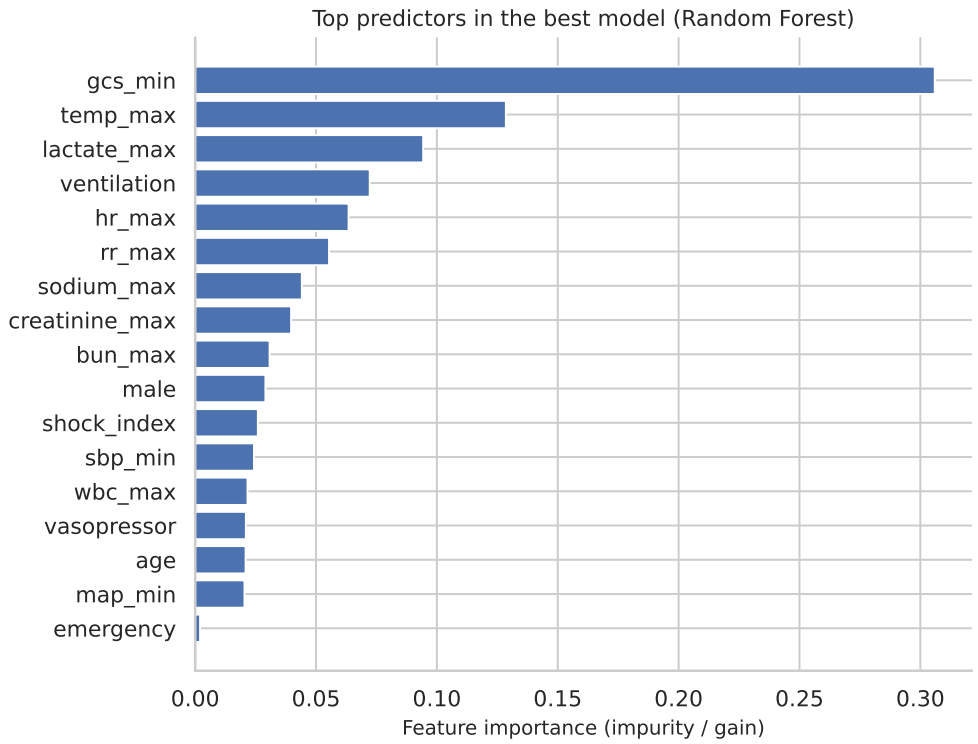


图 8: 随机森林特征重要性。Feature importance of the random forest.

SHAP 蜂群图（图 9）进一步显示了效应的方向：GCS 越低，SHAP 值越正（风险越高）；体温越高、乳酸越高、实施机械通气、心率越快，风险越高。年龄和性别的贡献相对有限。SHAP 平均绝对值和基尼重要性的排序基本一致，说明模型的主要信号来自神经功能、灌注/代谢和呼吸支持三个方面。

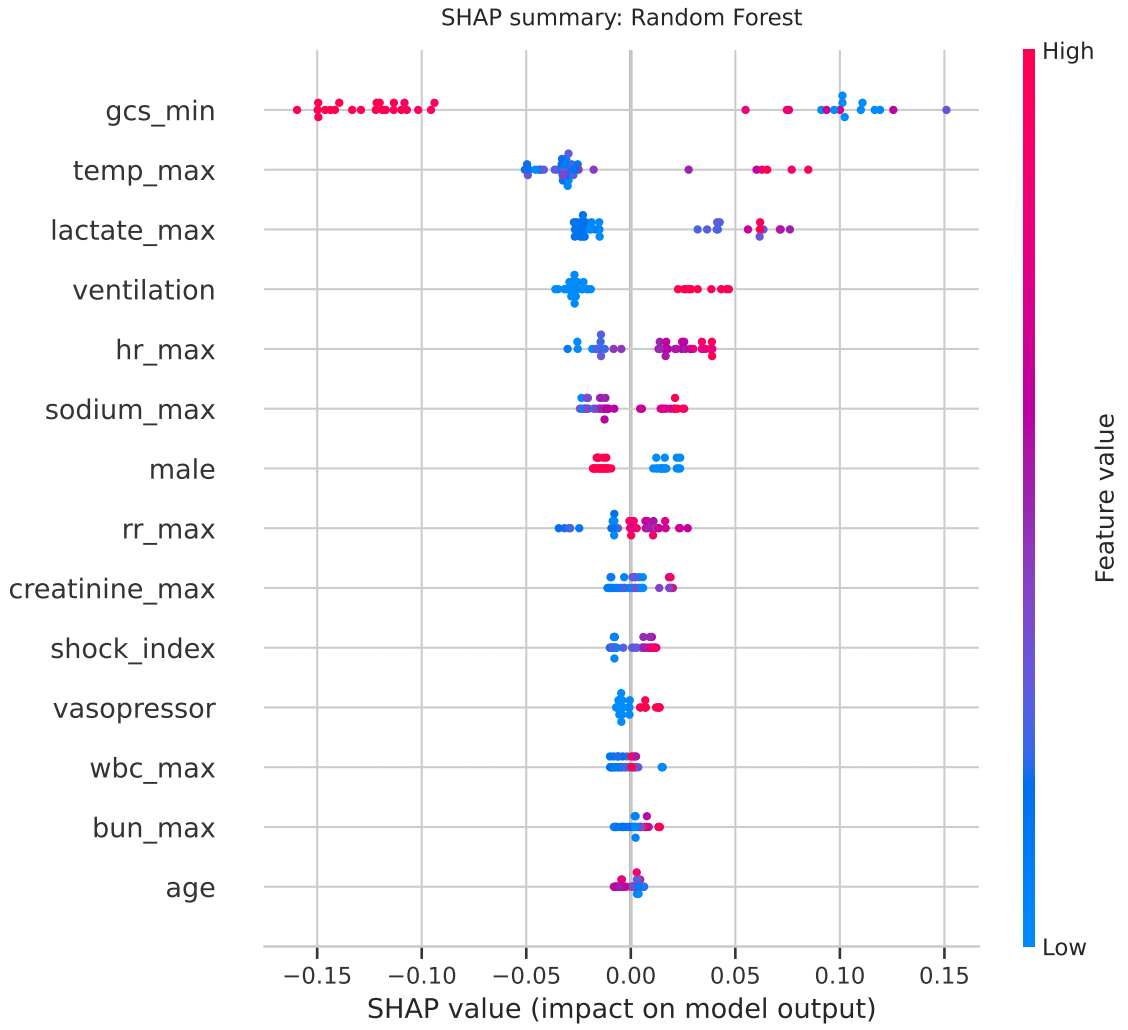


图 9: 随机森林的 SHAP 蜂群图。SHAP summary plot for the random forest.

3.5 交叉验证稳定性

5 折交叉验证的 AUROC 分布见图 10。随机森林的平均 AUROC 最高，但各折之间波动较大（0.583–0.935）；logistic 回归和 XGBoost 的折间波动相近。这一结果反映了小样本下模型性能的不确定性。

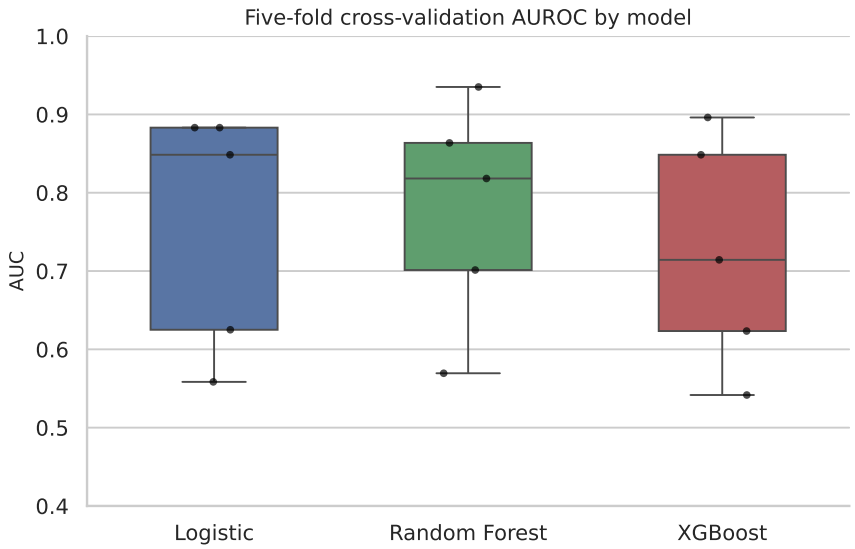


图 10: 5 折交叉验证 AUROC 分布。Five-fold cross-validation AUROC by model.

4 讨论

本研究基于公开的 MIMIC-IV Demo 数据，构建了一个从数据读取到模型解释的完整 ICU 延长住院预测流程。主要发现如下：（1）入 ICU 24 小时内的常规变量即可获得中等程度的区分能力（测试 AUROC 0.739–0.750）；（2）GCS、体温、乳酸、机械通气和心率是主要预测因素，与 ICU 疾病严重度的临床认识一致；（3）随机森林在交叉验证中表现最佳，但 logistic 回归在测试集上校准更好、可解释性更强，二者差异在样本量限制下不应过度解读。

GCS 是神经功能的核心指标，低 GCS 常提示意识障碍、镇静或神经系统损伤，与更长的机械通气、ICU 监护和康复时间相关。乳酸升高反映组织低灌注或无氧代谢，是休克和病情危重的标志。体温升高可能提示感染或全身炎症反应。机械通气本身既是呼吸衰竭的治疗措施，也是延长 ICU 停留的强预测因素。休克指数和血管活性药使用反映了血流动力学不稳定。上述变量均为 ICU 入科早期即可获得，不需要额外的特殊检查，因而具有较好的可推广性。

与既往研究相比，本模型的 AUROC 处于 0.7–0.8 的常见区间，但不同研究的队列、结局定义和时间窗差异较大，直接比较需谨慎。值得注意的是，延长 ICU 停留不仅由病情决定，还受出院流程、床位压力和医院管理的影响，因此任何生理学模型的预测上限都受到限制。临床使用时，模型输出应作为辅助信息，与床旁评估和资源状况结合。

模型选择方面，随机森林在交叉验证 AUROC 上略优于 logistic 回归（0.778 vs 0.760），但两者差异小于折间标准差；在独立测试集上，logistic 回归的 AUROC（0.750）和 Brier score（0.183）反而更好。对于小样本临床预测问题，简单的正则化 logistic 回归往往更稳健、更易校准，也更容易解释和部署。因此，若以临床落地为目标，logistic 回归可能是更合理的选择；随机森林则更适合作为非线性关系的探索工具。

5 局限性

本研究存在以下局限：

1. **样本量小**：Demo 仅包含 100 名患者、128 个首次 ICU 住院和 48 个事件，测试集只有 39 例。AUROC 的 95% CI 较宽（0.559–0.883），模型性能估计不稳定，也不适合进行复杂的亚组分析。
2. **单中心与回顾性设计**：MIMIC-IV 来自单一学术医疗中心，研究为回顾性观察，存在选择偏倚和信息偏倚。
3. **缺乏外部验证**：模型未在其他医院或完整 MIMIC-IV 队列中验证，不能直接外推。
4. **结局定义的局限**：ICU LOS $\geq$ 72 小时受出院流程、床位资源和医院管理影响，并非纯粹的生物学结局；不同的阈值可能改变事件率和模型表现。
5. **变量与时间窗的局限**：仅使用 24 小时内的最差值，未利用时间序列趋势、用药剂量、液体平衡、影像和护理记录；乳酸缺失率约 39%，中位数插补可能引入偏倚。
6. **模型选择的不确定性**：在 128 例样本上比较三种模型，交叉验证的折间方差较大，模型排名可能随随机种子和划分方式变化。

6 结论

基于 MIMIC-IV Demo 的入 ICU 24 小时常规数据，可以对延长 ICU 停留进行中等程度的早期预测。GCS、体温、乳酸、机械通气和心率是主要预测因素。随机森林在交叉验证中表现最佳，logistic 回归在测试集上校准更好且更易解释。受样本量限制，本研究应被视为可复现的方法学演示；未来需要在完整 MIMIC-IV 队列和多中心数据中进行外部验证，并纳入时间序列和治疗强度等信息。

数据与代码可用性

MIMIC-IV Clinical Database Demo v2.2 可从 PhysioNet 公开获取（DOI: 10.13026/dp1f-ex47）。本研究的 Jupyter Notebook、分析脚本、图表和结果表已随报告一并提交；数据读取、预处理、统计分析、建模、评估与可视化均可一键复现。

参考文献

[1] Johnson AEW, Bulgarelli L, Shen L, et al. MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*. 2023;10:1. doi:10.1038/s41597-022-01899-x.

[2] Johnson A, Bulgarelli L, Pollard T, Horng S, Celi LA, Mark R. MIMIC-IV Clinical Database Demo (version 2.2). *PhysioNet*. 2023. doi:10.13026/dp1f-ex47.

[3] Shickel B, Tighe PJ, Bihorac A, Rashidi P. Deep EHR: a survey of recent advances in deep learning techniques for electronic health record (EHR) analysis. *IEEE Journal of Biomedical and Health Informatics*. 2018;22(5):1589–1604.

[4] Kramer AA, Zimmerman JE. A predictive model for the early identification of patients at risk for a prolonged intensive care unit length of stay. *Critical Care Medicine*. 2011;39(6):1341–1349.

[5] Lundberg SM, Lee SI. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*. 2017;30:4765–4774.

[6] Van Calster B, McLernon DJ, van Smeden M, Wynants L, Steyerberg EW. Calibration: the Achilles heel of predictive analytics. *BMC Medicine*. 2019;17:230.

[7] Vickers AJ, Elkin EB. Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*. 2006;26(6):565–574.

[8] Collins GS, Moons KGM, Dhiman P, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*. 2024;385:e078378.

A 补充图表

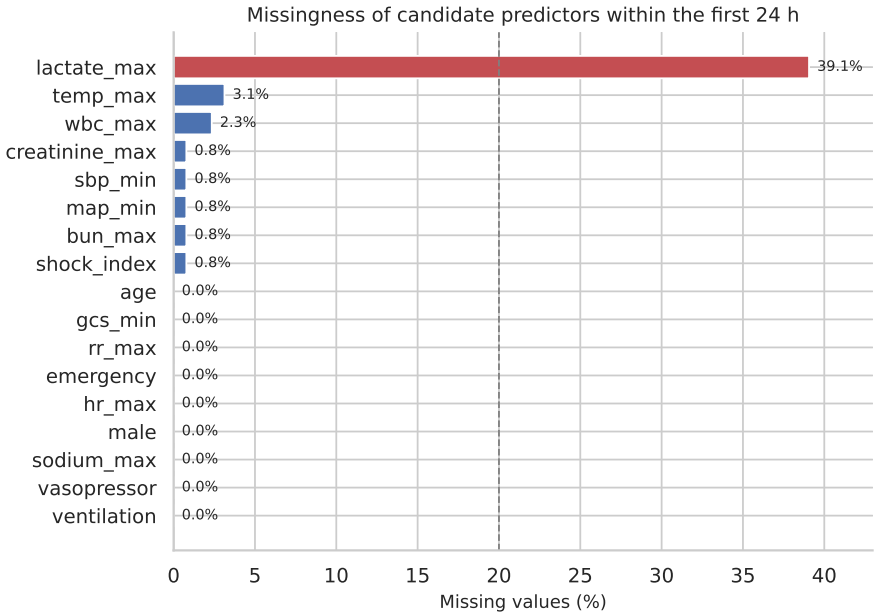


图 11: 候选预测变量的缺失率。Missingness of candidate predictors.

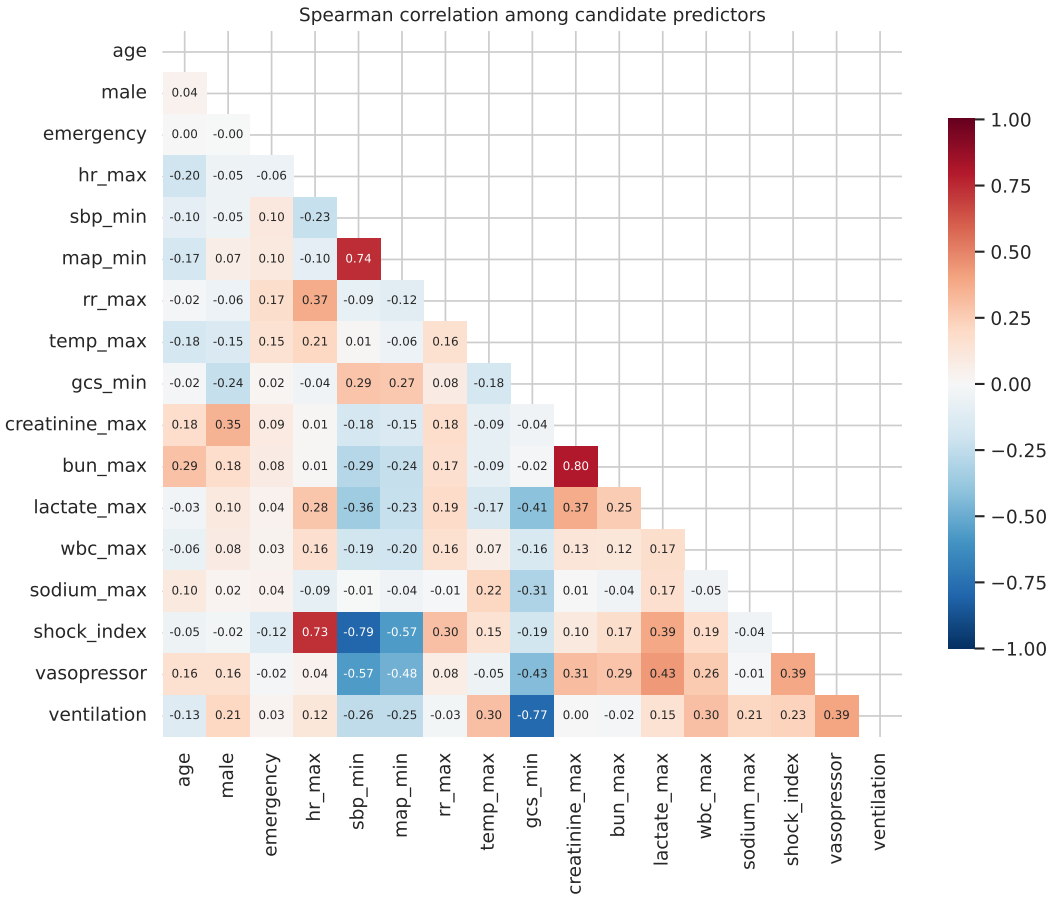


图 12: 候选预测变量间的 Spearman 相关性。Spearman correlations among candidate predictors.

B 超参数与复现说明

三种模型的最优超参数为：logistic 回归 $C = 0.1$；随机森林最大深度 3、每次分裂特征数 0.5、叶节点最小样本数 8；XGBoost 最大深度 3、L2 正则化系数 10。随机种子固定为 42，训练/测试划分为分层 70/30。所有插补与标准化均在训练集内拟合。完整流程见 `notebooks/01_mimic_icu_analysis.ipynb`。